

Pattern-wise ELW-CFMI:

基于观测模式经验似然加权的条件流匹配插补方法

方法说明与算法伪代码

1 方法动机

CFMI 的基本思想是用一个共享的条件连续正规化流 (conditional continuous normalizing flow, conditional CNF) 学习任意缺失模式下的条件分布

$$p_{\theta}(x_m | x_o), \quad (1)$$

其中 x_o 表示观测变量, x_m 表示缺失变量。训练时, 由于真实缺失值不可见, CFMI 在每个样本已经观测到的变量内部随机切分出 **conditioning variables** 与 **target variables**, 然后用 **conditional flow matching** 训练条件速度场。

在非 MCAR 情形下, 不同观测模式 $M = m$ 下的样本往往不是完整总体的随机样本。若直接在这些有偏观测样本上训练 CFMI, 模型学习到的条件关系可能更接近

$$p(x_t | x_c, M = m), \quad (2)$$

而不是总体意义下的目标条件分布

$$p(x_t | x_c). \quad (3)$$

因此, 可以先按观测模式分层, 在每个观测模式内估计样本级经验似然加权 (empirical likelihood weighting, ELW) 权重, 再将该权重加入 CFMI 的 flow matching 损失中。该方法可概括为

$$\boxed{\text{pattern-wise estimation, sample-wise weighting.}} \quad (4)$$

也就是说, 观测模式 m 用于划分子样本和估计权重; 真正进入神经网络训练目标的是每个样本自身的权重 $\hat{\omega}_i^{(m)}$ 。

2 符号定义

设完整数据为

$$X = (X_1, \dots, X_D) \in \mathbb{R}^D, \quad (5)$$

观测模式为

$$M \in \{0, 1\}^D, \quad (6)$$

其中 $M_j = 1$ 表示变量 X_j 被观测, $M_j = 0$ 表示变量 X_j 缺失。第 i 个不完整样本记为

$$(x_{i,o}, m_i), \quad i = 1, \dots, n. \quad (7)$$

给定观测模式 m , 定义该模式下的样本集合为

$$\mathcal{I}_m = \{i : m_i = m\}, \quad n_m = |\mathcal{I}_m|, \quad (8)$$

并定义所有出现过的观测模式集合为

$$\mathcal{M} = \{m : n_m > 0\}. \quad (9)$$

对样本 i , CFMI 训练时从其观测维度中随机切分出两部分 **mask**:

$$s_{i,c} \in \{0, 1\}^D, \quad s_{i,t} \in \{0, 1\}^D, \quad (10)$$

其中 $s_{i,c}$ 表示 **conditioning mask**, $s_{i,t}$ 表示 **target mask**, 并满足

$$s_{i,c} \odot s_{i,t} = 0, \quad s_{i,c} + s_{i,t} \leq m_i. \quad (11)$$

也就是说, 训练阶段只能从已经观测到的变量中选择 **condition** 和 **target**, 真实缺失维度不能被选入训练监督。

3 Pattern-wise ELW 样本权重

对每个观测模式 $m \in \mathcal{M}$, 在子样本 $\mathcal{I}_m$ 内估计一组样本级 ELW 权重

$$\hat{\omega}_i^{(m)}, \quad i \in \mathcal{I}_m, \quad (12)$$

并要求

$$\hat{\omega}_i^{(m)} \geq 0, \quad \sum_{i \in \mathcal{I}_m} \hat{\omega}_i^{(m)} = 1. \quad (13)$$

这些权重的作用是将模式 m 下的有偏经验分布校正为更接近目标总体分布。一般可以通过如下经验似然约束形式理解:

$$\max_{\{\omega_i^{(m)}\}_{i \in \mathcal{I}_m}} \sum_{i \in \mathcal{I}_m} \log \omega_i^{(m)}, \quad (14)$$

$$\text{s.t.} \quad \sum_{i \in \mathcal{I}_m} \omega_i^{(m)} = 1, \quad \omega_i^{(m)} \geq 0, \quad (15)$$

$$\sum_{i \in \mathcal{I}_m} \omega_i^{(m)} g_m(x_{i,o}) = \hat{\mu}_m. \quad (16)$$

其中 $g_m(\cdot)$ 是选定的平衡函数或估计方程, $\hat{\mu}_m$ 是目标矩或由外部信息、全样本可观测信息得到的校准量。实际论文中可以根据 ELW 的具体形式设定 g_m 与 $\hat{\mu}_m$, 例如使用 propensity score、协变量矩条件, 或与观测模式相关的平衡约束。

模式层面还可以引入权重 ρ_m 。若不希望改变不同观测模式在训练目标中的总体占比, 可以取经验频率

$$\rho_m = \frac{n_m}{n}. \quad (17)$$

4 ELW-CFMI 的加权训练目标

对第 i 个样本, 在一次随机切分 $(s_{i,c}, s_{i,t})$ 下, 令

$$x_{i,c} = x_i[s_{i,c}], \quad x_{i,t} = x_i[s_{i,t}]. \quad (18)$$

从标准正态分布采样

$$z_{i,t} \sim \mathcal{N}(0, I_{\|s_{i,t}\|_0}), \quad (19)$$

并取线性 flow matching 路径

$$x_{i,t}^\tau = \tau x_{i,t} + (1 - \tau) z_{i,t}, \quad \tau \sim \text{Unif}(0, 1). \quad (20)$$

由于本版本暂不引入 Impute-MACFM 的非线性 schedule, 目标速度场为

$$u_i = x_{i,t} - z_{i,t}. \quad (21)$$

设 $\tilde{x}_{i,t}^\tau$ 与 $\tilde{x}_{i,c}$ 分别表示补零到 D 维后的 target path state 与 condition vector。CFMI 的单样本条件流匹配损失为

$$\ell_i(\theta) = \mathbb{E}_{s_{i,c}, s_{i,t}, \tau, z} \left[\frac{1}{\|s_{i,t}\|_0} \left\| v_\theta(\tilde{x}_{i,t}^\tau; \tilde{x}_{i,c}, s_{i,c}, \tau)[s_{i,t}] - u_i \right\|_2^2 \right]. \quad (22)$$

加入样本级 ELW 权重后, 总训练目标为

$$\mathcal{L}_{\text{PW-ELW-CFMI}}(\theta) = \sum_{m \in \mathcal{M}} \rho_m \sum_{i \in \mathcal{I}_m} \hat{\omega}_i^{(m)} \ell_i(\theta). \quad (23)$$

如果取

$$\rho_m = \frac{n_m}{n}, \quad \hat{\omega}_i^{(m)} = \frac{1}{n_m}, \quad (24)$$

则有

$$\mathcal{L}_{\text{PW-ELW-CFMI}}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell_i(\theta), \quad (25)$$

即退化为原始未加权 CFMI 训练目标。

5 插补阶段

训练完成后, 对一个待插补样本 (x_o, m) , 直接将观测变量作为 **condition**, 将缺失变量作为 **target**:

$$s_c = m, \quad s_t = 1 - m. \quad (26)$$

初始化

$$x_m^{(0)} \sim \mathcal{N}(0, I_{\|1-m\|_0}). \quad (27)$$

然后用训练好的速度场求解 ODE:

$$\frac{dx_m^\tau}{d\tau} = v_\theta(\tilde{x}_m^\tau; \tilde{x}_o, m, \tau)[1 - m], \quad \tau \in [0, 1]. \quad (28)$$

使用 Euler 离散化时, 令 $\Delta = 1/K$, 有

$$x_m^{(k+1)} = x_m^{(k)} + \Delta v_\theta(\tilde{x}_m^{(k)}; \tilde{x}_o, m, k/K)[1 - m], \quad k = 0, \dots, K - 1. \quad (29)$$

最终得到

$$\hat{x}_m = x_m^{(K)}. \quad (30)$$

如果需要多重插补, 重复采样不同的初始噪声 $x_m^{(0)}$ 即可得到多组插补值。

6 算法伪代码

Algorithm 1: Pattern-wise ELW-CFMI Training

输入: 不完整训练数据 $\{(x_{i,o}, m_i)\}_{i=1}^n$; 切分策略 $q(s_c, s_t | m)$; 模式权重 ρ_m ; 训练步数 T ; 批量大小 B 。

输出: 训练后的条件速度场 v_{θ} 。

- 1 按观测模式分组: $\mathcal{I}_m = \{i : m_i = m\}, m \in \mathcal{M}$ 。
- 2 **for each** $m \in \mathcal{M}$ **do**
- 3 在子样本 $\mathcal{I}_m$ 内估计样本级 ELW 权重 $\{\hat{\omega}_i^{(m)} : i \in \mathcal{I}_m\}$, 使 $\sum_{i \in \mathcal{I}_m} \hat{\omega}_i^{(m)} = 1$ 。
- 4 初始化神经网络参数 θ 。
- 5 **for** $r = 1, \dots, T$ **do**
- 6 抽取 mini-batch $\mathcal{B}$ 。
- 7 **for each** $i \in \mathcal{B}$ **do**
- 8 根据 $q(s_c, s_t | m_i)$ 在观测变量内部随机切分, 得到 $s_{i,c}$ 与 $s_{i,t}$, 满足
 $s_{i,c} \odot s_{i,t} = 0$ 且 $s_{i,c} + s_{i,t} \leq m_i$ 。
- 9 构造 $x_{i,c} = x_i[s_{i,c}]$, $x_{i,t} = x_i[s_{i,t}]$ 。
- 10 采样 $\tau_i \sim \text{Unif}(0, 1)$, $z_{i,t} \sim \mathcal{N}(0, I)$ 。
- 11 构造线性路径与目标速度: $x_{i,t}^{\tau_i} = \tau_i x_{i,t} + (1 - \tau_i) z_{i,t}$, $u_i = x_{i,t} - z_{i,t}$ 。
- 12 计算单样本 flow matching loss

$$\ell_i(\theta) = \frac{1}{\|s_{i,t}\|_0} \|v_{\theta}(\tilde{x}_{i,t}^{\tau_i}, \tilde{x}_{i,c}, s_{i,c}, \tau_i)[s_{i,t}] - u_i\|_2^2.$$

 取样本训练权重 $a_i = \rho_{m_i} \hat{\omega}_i^{(m_i)}$ 。
- 13 形成 mini-batch 加权损失

$$\hat{\mathcal{L}}_{\mathcal{B}}(\theta) = \sum_{i \in \mathcal{B}} a_i \ell_i(\theta).$$

 对 θ 做一次梯度更新。
- 14 **返回** v_{θ} 。

Algorithm 2: Pattern-wise ELW-CFMI Imputation

输入: 待插补样本 (x_o, m) ; 训练后的速度场 v_θ ; ODE 步数 K ; 插补次数 L 。

输出: L 组插补结果 $\{\hat{x}_m^{(\ell)}\}_{\ell=1}^L$ 。

```

1  设置推断阶段的 condition 与 target mask:  $s_c = m, s_t = 1 - m$ 。
2  for  $\ell = 1, \dots, L$  do
3      初始化缺失部分:  $x_m^{(0,\ell)} \sim \mathcal{N}(0, I_{\|1-m\|_0})$ 。
4      令  $\Delta = 1/K$ 。
5      for  $k = 0, \dots, K - 1$  do
6          
$$x_m^{(k+1,\ell)} = x_m^{(k,\ell)} + \Delta v_\theta(\tilde{x}_m^{(k,\ell)}; \tilde{x}_o, m, k/K)[1 - m].$$

7      输出第  $\ell$  组插补:  $\hat{x}_m^{(\ell)} = x_m^{(K,\ell)}$ 。
8  返回  $\{\hat{x}_m^{(\ell)}\}_{\ell=1}^L$ 。
    
```

7 方法特点

- **样本级加权。** ELW 权重最终对应到每个样本，而不是每个观测模式一个常数权重。
- **模式内估计。** 按 $M = m$ 分组估计 $\hat{\omega}_i^{(m)}$ ，可以针对不同观测模式的选择偏差进行校正。
- **共享 CFMI 模型。** 不为每个模式单独训练生成模型，而是训练一个共享条件速度场 v_θ ，保留 CFMI 对多种缺失模式的可扩展性。
- **基础版本便于理论分析。** 本版本不使用非线性 schedule、不使用 $s'(t)(X - \varepsilon)$ 的 schedule-consistent velocity，也不引入 projection 约束；因此它是最基础、最便于理论分析的 Pattern-wise ELW-CFMI 版本。

8 可作为论文中的表述

可将该方法概括为：在 MAR 与 positivity 条件下，不同观测模式对应的观测样本可能存在模式选择偏差。为缓解该问题，本文提出 Pattern-wise ELW-CFMI 方法：先按观测模式对样本进行分层，在每个观测模式内通过经验似然思想估计样本级权重，再将该权重嵌入 conditional flow matching 的训练目标中，从而使共享条件生成模型在训练时更接近目标总体下的条件分布。该方法在结构上保留 CFMI 的共享条件建模优势，同时通过 ELW 权重引入对观测模式偏倚的稳定校正。